# cholesterol-analysis

November 13, 2024

# 1 Cholesterol Analysis and Modelling

Dalam proyek ini, kami bertujuan untuk membangun model prediktif faktor-faktor kesehatan apa yang paling berpengaruh terhadap nilai kolesterol total. Kumpulan data berisi sejumlah variabel seperti tekanan darah sistolik dan diastolik, IMT, glukosa puasa, serta trigliserida.

**Tahapan Analisis** \* Data Cleaning \* Exploratory Data Analysis \* Transformasi data \* Model Building \* Evaluate Model Performance

## 1.1 Import Libraries

```
[1]: from google.colab import drive drive.mount('/content/drive')
```

Mounted at /content/drive

```
[]: import os
  import pandas as pd
  import matplotlib.pyplot as plt
  import seaborn as sns
  import numpy as np
  import statistics
  from sklearn.preprocessing import LabelEncoder
  from imblearn.over_sampling import SMOTE
  from sklearn.model_selection import train_test_split
  import statsmodels.api as sm
```

#### 1.2 Read Dataset

Dataset ini merupakan data sampel hasil survey kesehatan suatu perusahaan terhadap pegawainya. Dataset ini menyediakan informasi 1339 pegawai dan 15 variabel yang diukur dengan tipe data kategorik dan numerik.

Tujuan analisis ini adalah mencari variabel apa yang paling berpengaruh terhadap tingkat kolesterol seorang pegawai.

## Deskripsi Dataset

Index	Variable	Keterangan
1	Jenis kelamin	Variabel yang menunjukkan jenis kelamin responden, laki-laki atau perempuan.
2	Usia	Variabel yang mengindikasikan usia responden dalam tahun.
3	Tekanan darah (S)	Variabel yang mencatat tekanan darah sistolik responden.
4	Tekanan darah (D)	Variabel yang mencatat tekanan darah diastolik responden.
5	Tinggi badan (cm)	Variabel yang mencatat tinggi badan responden dalam sentimeter.
6	Berat badan (kg)	Variabel yang mencatat berat badan responden dalam kilogram.
7	$\mathrm{IMT}\ (\mathrm{kg/m2})$	Variabel yang menunjukkan Indeks Massa Tubuh (IMT) responden, dihitung sebagai berat badan dalam kilogram dibagi dengan kuadrat tinggi badan dalam meter.
8	Lingkar perut (cm)	Variabel yang mencatat lingkar perut responden dalam sentimeter.
9	Glukosa Puasa (mg/dL)	Variabel yang mencatat kadar glukosa darah puasa responden dalam miligram per desiliter (mg/dL).
10	Cholesterol Total (mg/dL)	Variabel yang mencatat kadar kolesterol total dalam darah responden dalam miligram per desiliter (mg/dL).
11	Trigliserida (mg/dL)	Variabel yang mencatat kadar trigliserida dalam darah responden dalam miligram per desiliter (mg/dL).

Index	Variable	Keterangan
12	Fat	Variabel yang mencatat persentase lemak tubuh responden.
13	Visceral Fat	Persentase lemak visceral (lemak di sekitar organ dalam) dari total lemak tubuh responden.
14	Masa Kerja	Lama masa kerja responden dalam satuan waktu tertentu, misalnya dalam tahun.
15	Tempat lahir	Lokasi tempat lahir responden.

```
[ ]: path = '/content/drive/MyDrive/ETAM SCIENCE/'
    df = pd.read_csv(os.path.join(path, "data.csv"))
    df.drop(columns=(['Responden', 'Tempat lahir']), inplace=True)
    df.head()
```

[]:	Jenis Kelamin	Usia	Tekanan darah (S)	Tekanan darah (D)	\
0	M	19.0	126.0	88.0	
1	M	19.0	120.0	80.0	
2	M	19.0	120.0	80.0	
3	F	19.0	100.0	70.0	
4	М	19.0	110.0	70.0	

	Tinggi badan (cm)	Berat badan (kg)	IMT (kg/m2)	Lingkar perut (cm)	\
0	172.5	49.5	16.53	66.0	
1	158.0	53.6	21.50	71.0	
2	170.0	59.5	20.59	80.0	
3	149.0	45.1	20.31	62.0	
4	171.6	62.4	21.19	78.0	

	Glukosa Puasa (mg/dL)	Cholesterol Total (mg/dL)	Trigliserida (mg/dL)	\
0	84.0	187.0	99.0	
1	84.0	187.0	99.0	
2	80.0	187.0	99.0	
3	81.0	187.0	99.0	
4	84.0	187.0	99.0	

```
Fat Visceral Fat Masa Kerja
0 26.4 6.0 0.97
1 26.4 6.0 0.60
2 26.4 6.0 1.37
```

3	30.5	3.5	1.00
4	26.4	6.0	4.00

# 1.3 Data Cleaning

Melakukan identifikasi dan pembersihan pada dataset yang memiliki missing value, outlier, dan data duplikat.

## Identifikasi missing value

Mengidentifikasi missing value pada dataset

```
[]:
                                  number_of_missing
     Jenis Kelamin
                                                   0
                                                   0
     Usia
     Tekanan darah (S)
                                                   0
     Tekanan darah (D)
                                                   0
     Tinggi badan (cm)
                                                   0
                                                   0
     Berat badan (kg)
     IMT (kg/m2)
                                                   0
     Lingkar perut (cm)
                                                   0
     Glukosa Puasa (mg/dL)
                                                   0
                                                   0
     Cholesterol Total (mg/dL)
     Trigliserida (mg/dL)
                                                   0
     Fat
                                                   0
     Visceral Fat
                                                   0
     Masa Kerja
                                                   0
```

```
Set_of_value \
Jenis Kelamin

Usia

{19.0, 20.0, 21.0, 22.0, 23.0, 24.0, 25.0, 26...}

Tekanan darah (S)

Tekanan darah (D)

{58.0, 60.0, 61.0, 62.0, 63.0, 64.0, 65.0, 66...}

Tinggi badan (cm)

Berat badan (kg)

{58.05, 38.5, 39.85, 40.5, 40.2, 42.4, 43.5, 4...}

[MT (kg/m2)

Set_of_value \
F, M}

{19.0, 20.0, 21.0, 22.0, 23.0, 24.0, 25.0, 26...}

{128.0, 129.0, 130.0, 131.0, 132.0, 138.0, 140...}

{58.0, 60.0, 61.0, 62.0, 63.0, 64.0, 65.0, 66...}

{172.4, 170.2, 161.8, 164.3, 164.8, 138.5, 144...}

[58.05, 38.5, 39.85, 40.5, 40.2, 42.4, 43.5, 4...]
```


Lingkar perut (cm)	{102.5, 103.0, 104.0, 54.0, 56.0, 57.0, 59.0,
Glukosa Puasa (mg/dL)	{130.0, 143.0, 321.0, 277.0, 285.0, 68.0, 65.0
Cholesterol Total (mg/dL)	{103.0, 104.0, 114.0, 118.0, 119.0, 120.0, 122
Trigliserida (mg/dL)	{34.0, 35.0, 37.0, 38.0, 39.0, 40.0, 41.0, 43
Fat	{5.8, 6.8, 7.5, 7.4, 9.5, 10.4, 11.1, 11.9, 13
Visceral Fat	{0.5, 1.0, 2.0, 3.5, 1.5, 4.5, 6.0, 7.0, 2.5,
Masa Kerja	{0.97, 1.37, 1.0, 1.01, 4.0, 2.0, 6.0, 2.81, 8

	${\tt maximum}$	data_type	number_of_value
Jenis Kelamin	NaN	object	2
Usia	39.00	float64	21
Tekanan darah (S)	170.00	float64	35
Tekanan darah (D)	100.00	float64	34
Tinggi badan (cm)	187.50	float64	213
Berat badan (kg)	139.75	float64	664
IMT (kg/m2)	44.10	float64	733
Lingkar perut (cm)	128.00	float64	95
Glukosa Puasa (mg/dL)	321.00	float64	50
Cholesterol Total (mg/dL)	308.00	float64	144
Trigliserida (mg/dL)	634.00	float64	187
Fat	40.90	float64	177
Visceral Fat	23.00	float64	43
Masa Kerja	31.00	float64	237

## Identifikasi Outliers

dilakukan identifikasi outlier pada setiap variabel dataset dan menghitung jumlah outlier yang terbentuk.

```
[]: df.boxplot(figsize=(20, 6))
plt.title('Boxplot Semua Variabel')
plt.show()
```




```
[]: # Fungsi Pendeteksian Outlier dengan IQR
     def detect_outliers_iqr(data):
         outliers = []
         data = sorted(data)
         q1 = np.percentile(data, 25)
         q3 = np.percentile(data, 75)
         IQR = q3-q1
         lwr_bound = q1-(1.5*IQR)
         upr_bound = q3+(1.5*IQR)
         for i in data:
             if (i<lwr_bound or i>upr_bound):
                 outliers.append(i)
         return outliers
     sample_outliers = detect_outliers_iqr(df['Trigliserida (mg/dL)'])
     # print("Outliers from IQR method: ", sample_outliers)
     len(sample_outliers)
     # sample_outliers
```

[]: 548

Mengidentifikasi jumlah outlier pada salah satu variabel yaitu variabel trigliserida

```
[]: plt.boxplot(df['Trigliserida (mg/dL)'], vert=False)
   plt.title("Boxplot Trigliserida")
   plt.xlabel('Overs')
```

[]: Text(0.5, 0, 'Overs')



# Identifikasi data duplikat

Mengidentifikasi data yang duplikat pada dataset

```
[]: df.duplicated(keep=False).sum()
```

[]: 0

# 1.4 Exploratory Data Analysis

# Statistika Deskriptif

Menampilkan tabel statistika deskriptif pada seleuruh variabel dataset

```
[]: #statistika deskriptif
df.describe()
```

```
[]:
                   Usia Tekanan darah (S)
                                            Tekanan darah (D)
                                                                Tinggi badan (cm)
           1339.000000
                               1339.000000
                                                   1339.000000
                                                                      1339.000000
     count
    mean
              28.597461
                                113.147872
                                                     74.009709
                                                                       164.940851
               4.767230
                                 10.164592
                                                      7.718752
                                                                         7.386617
     std
```


```
19.000000
                              80.000000
                                                  58.000000
                                                                      138.500000
min
25%
         25.000000
                             110.000000
                                                  70.000000
                                                                      160.000000
50%
         28.000000
                             110.000000
                                                  72.000000
                                                                     165.000000
75%
         31.000000
                             120.000000
                                                  80.00000
                                                                     170.000000
         39.000000
                             170.000000
                                                 100.000000
                                                                     187.500000
max
       Berat badan (kg)
                          IMT (kg/m2)
                                        Lingkar perut (cm)
             1339.000000
                           1339.000000
                                                1339.000000
count
               64.620500
                             23.693727
                                                  80.441972
mean
std
               12.799096
                              4.021585
                                                  10.688215
min
               38.500000
                             14.850000
                                                  54.000000
25%
               55.275000
                                                  72.000000
                             20.855000
50%
               62.500000
                             23.200000
                                                  80.000000
75%
               71.775000
                             26.000000
                                                  87.000000
              139.750000
                             44.100000
                                                 128.000000
max
       Glukosa Puasa (mg/dL)
                                Cholesterol Total (mg/dL)
                                                             Trigliserida (mg/dL)
                  1339.000000
                                               1339.000000
                                                                       1339.000000
count
                    84.571322
                                                187.995519
                                                                        106.982823
mean
std
                    11.522057
                                                 21.104834
                                                                         44.143456
min
                    65.000000
                                                103.000000
                                                                         34.000000
25%
                    84.000000
                                                187.000000
                                                                         99.000000
50%
                    84.000000
                                                                         99.000000
                                                187.000000
75%
                    84.000000
                                                187.000000
                                                                         99.000000
                   321.000000
                                                                        634.000000
max
                                                308.000000
                Fat
                     Visceral Fat
                                     Masa Kerja
       1339.000000
                                    1339.000000
count
                      1339.000000
                                        6.401837
mean
         26.203510
                         6.231367
           3.678467
                         2.431923
                                        4.554438
std
min
           5.800000
                         0.500000
                                        0.000000
25%
         26.400000
                         6.000000
                                        4.000000
50%
         26.400000
                         6.000000
                                        6.000000
75%
         26.400000
                         6.000000
                                        8.000000
         40.900000
                         23.000000
                                      31.000000
max
```

#### Matriks Korelasi

Menampilkan matriks korelasi pada seluruh variabel

```
[]: df_numeric = df.select_dtypes(include=[np.number])
    corr_matrix = df_numeric.corr()

sns.heatmap(corr_matrix, linewidths=0.5, annot=True, cmap='RdYlGn')
plt.gcf().set_size_inches(15, 8)
plt.show()
```



```
[]: # Variabel Y

df['Cholesterol Total (mg/dL)'] = df['Cholesterol Total (mg/dL)'].apply(lambda

∴x : 'normal' if x < 200 else 'tinggi')

# Trigliserida

df['Trigliserida (mg/dL)'] = df['Trigliserida (mg/dL)'].apply(lambda x:


∴'normal' if x < 150 else 'tinggi')
```

```
[]: sns.countplot(x='Cholesterol Total (mg/dL)',data=df, palette='hls') plt.show()
```

<ipython-input-12-f5a811f2ef8d>:1: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

sns.countplot(x='Cholesterol Total (mg/dL)',data=df, palette='hls')



```
[]: df['Cholesterol Total (mg/dL)'].value_counts()
[]: Cholesterol Total (mg/dL)
    normal
               1141
                198
     tinggi
     Name: count, dtype: int64
[]: selected_columns = ['Usia', 'Tinggi badan (cm)', 'Berat badan (kg)', 'IMT (kg/
      →m2)', 'Glukosa Puasa (mg/dL)',
                         'Lingkar perut (cm)', 'Masa Kerja']
     grouped_mean = df.groupby('Cholesterol Total (mg/dL)')[selected_columns].mean()
     print(grouped_mean)
                                    Usia Tinggi badan (cm) Berat badan (kg) \
    Cholesterol Total (mg/dL)
    normal
                               27.987730
                                                  164.972656
                                                                     64.203129
                               32.111111
                                                  164.757576
                                                                     67.025657
    tinggi
                               IMT (kg/m2)
                                            Glukosa Puasa (mg/dL)
    Cholesterol Total (mg/dL)
    normal
                                 23.536398
                                                         84.377739
```


tinggi 24.600354 85.686869

Lingkar perut (cm) Masa Kerja

Cholesterol Total (mg/dL)
normal 80.059159 6.179395
tinggi 82.647980 7.683687


```
[]: df.Usia.hist()
  plt.title('Histogram of Age')
  plt.xlabel('Usia')
  plt.ylabel('Frequency')
```

# []: Text(0, 0.5, 'Frequency')



## Membandingkan variabel cholesterol dengan trigliserida

Untuk mengetahui apakah jika trigliserida masuk dalam kategori normal maka juga memiliki tingkat kolesterol normal atau tidak



## **Boxplot**

Menampilkan boxplot variabel usia dan kolesterol untuk mengetahui rentang usia pada variabel kolesterol

```
import seaborn as sns
import matplotlib.pyplot as plt

# Boxplot Usia berdasarkan kategori kolestrol
plt.figure(figsize=(8, 6))
sns.boxplot(x='Cholesterol Total (mg/dL)', y='Usia', data=df, palette='pastel')

# Menambahkan nilai pada boxplot
for i in range(len(df['Cholesterol Total (mg/dL)'].unique())):
    box_data = df[df['Cholesterol Total (mg/dL)'] == df['Cholesterol Total (mg/dL)'].unique()[i]]['Usia']
```

```
whisker_bottom = box_data.min()
    whisker_top = box_data.max()
    median = box_data.median()
    quartile_25 = box_data.quantile(0.25)
    quartile_75 = box_data.quantile(0.75)
    plt.annotate(f'Min: {whisker_bottom}', xy=(i, whisker_bottom), xytext=(i+0.
 ⇔1, whisker_bottom), color='black')
    plt.annotate(f'25th: {quartile_25}', xy=(i, quartile_25), xytext=(i+0.1, u)

¬quartile_25), color='black')

    plt.annotate(f'Median: {median}', xy=(i, median), xytext=(i+0.1, median),
 ⇔color='black')
    plt.annotate(f'75th: {quartile_75}', xy=(i, quartile_75), xytext=(i+0.1,__


¬quartile_75), color='black')

    plt.annotate(f'Max: {whisker_top}', xy=(i, whisker_top), xytext=(i+0.1,__
 ⇔whisker_top), color='black')
plt.title('Hubungan antara Usia dan Kolesterol')
plt.xlabel('(0 = Kolesterol normal, 1 = Kolesterol tinggi)')
plt.ylabel('Usia')
plt.show()
```

<ipython-input-17-ae7526c66e7c>:6: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

sns.boxplot(x='Cholesterol Total (mg/dL)', y='Usia', data=df,
palette='pastel')



# 1.5 Transformasi data

Dilakukan penanganan pada data kategorik dengan membuat data dummy sesuai dengan kategori yang telah ditentukan

Dilakukan labeling data sesuai dengan kategori berikut

Index	Variable	Keterangan
1	Jenis kelamin	0 = wanita, 1 = pria
2	Usia	00 = <=35  tahun, 10 = 36-50  tahun, 01 = >50  tahun
3	IMT (kg/m2)	000 = kurus(<18.5), 100 = normal(18.5-24), 010 =
		kegemukan(25-26), 001 = obesitas(>26)
4	Glukosa Puasa (mg/dL)	0 = normal (100), 1 = pra-diabetes/tidak normal (>100)
5	Cholesterol Total (mg/dL)	0 = normal (<200), 1 = tinggi (200)
6	Trigliserida (mg/dL)	0 = normal (<150), 1 = tinggi (150)

```
[]: # Jenis Kelamin
     df['Jenis Kelamin'] = df['Jenis Kelamin'].apply(lambda x: 'Wanita' if x == 'F'
      →else 'Pria')
     # Usia
     df['Usia'] = df['Usia'].apply(lambda x: '0' if 19 <= x <= 35 else ('1' if 36 <=_\)
      \hookrightarrow x \ll 50 \text{ else '2'})
     # IMT
     df['IMT (kg/m2)'] = df['IMT (kg/m2)'].apply(lambda x: '0' if x < 18.5 else ('1'_\_
      \Rightarrowif 18.5 <= x < 25.0 else ('2' if 25.0 <= x < 27.0 else '3')))
     # Glukosa Puasa
     df['Glukosa Puasa (mg/dL)'] = df['Glukosa Puasa (mg/dL)'].apply(lambda x: '0'
      \rightarrowif x < 100 else '1')
     df[['Jenis Kelamin','Cholesterol Total (mg/dL)', 'Glukosa Puasa (mg/
      _{\hookrightarrow}dL)','Trigliserida (mg/dL)', 'IMT (kg/m2)','Usia']] = df[['Jenis_\( \)
      ⊸Kelamin','Cholesterol Total (mg/dL)', 'Glukosa Puasa (mg/dL)','Trigliserida⊔
       _{\hookrightarrow}(mg/dL)', 'IMT (kg/m2)', 'Usia']] .astype('category')
```

## []: df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1339 entries, 0 to 1338
Data columns (total 14 columns):

#	Column	Non-Null Count	Dtype			
0	Jenis Kelamin	1339 non-null	category			
1	Usia	1339 non-null	category			
2	Tekanan darah (S)	1339 non-null	float64			
3	Tekanan darah (D)	1339 non-null	float64			
4	Tinggi badan (cm)	1339 non-null	float64			
5	Berat badan (kg)	1339 non-null	float64			
6	IMT (kg/m2)	1339 non-null	category			
7	Lingkar perut (cm)	1339 non-null	float64			
8	Glukosa Puasa (mg/dL)	1339 non-null	category			
9	Cholesterol Total (mg/dL)	1339 non-null	category			
10	Trigliserida (mg/dL)	1339 non-null	category			
11	Fat	1339 non-null	float64			
12	Visceral Fat	1339 non-null	float64			
13	Masa Kerja	1339 non-null	float64			
dtypes: category(6), float64(8)						
memo	memory usage: 92.5 KB					

#### Membuat Data Dummy

Data dummy dibuat pada variabel kategori yaitu usia, IMT, jenis kelamin, glukosa puasa, cholesterol total, dan trigliserida

```
[]: cat_vars = ['Usia', 'IMT (kg/m2)', 'Jenis Kelamin', 'Glukosa Puasa (mg/dL)', u
      ⇔'Cholesterol Total (mg/dL)','Trigliserida (mg/dL)']
     for var in cat_vars:
         cat_list = pd.get_dummies(df[var], prefix=var)
         df = pd.concat([df, cat_list], axis=1)
     df.drop(cat_vars, axis=1, inplace=True)
     print(df.columns.values)
    ['Tekanan darah (S)' 'Tekanan darah (D)' 'Tinggi badan (cm)'
     'Berat badan (kg)' 'Lingkar perut (cm)' 'Fat' 'Visceral Fat' 'Masa Kerja'
     'Usia_0' 'Usia_1' 'IMT (kg/m2)_0' 'IMT (kg/m2)_1' 'IMT (kg/m2)_2'
     'IMT (kg/m2)_3' 'Jenis Kelamin_Pria' 'Jenis Kelamin_Wanita'
     'Glukosa Puasa (mg/dL)_0' 'Glukosa Puasa (mg/dL)_1'
     'Cholesterol Total (mg/dL)_normal' 'Cholesterol Total (mg/dL)_tinggi'
     'Trigliserida (mg/dL)_normal' 'Trigliserida (mg/dL)_tinggi']
[]: df.head()
[]:
        Tekanan darah (S)
                           Tekanan darah (D)
                                               Tinggi badan (cm) Berat badan (kg) \
     0
                    126.0
                                         88.0
                                                           172.5
                                                                               49.5
     1
                    120.0
                                         80.0
                                                           158.0
                                                                               53.6
     2
                    120.0
                                         80.0
                                                           170.0
                                                                               59.5
     3
                    100.0
                                         70.0
                                                           149.0
                                                                               45.1
     4
                    110.0
                                         70.0
                                                           171.6
                                                                               62.4
        Lingkar perut (cm)
                             Fat Visceral Fat Masa Kerja Usia_0 Usia_1 ... \
     0
                      66.0
                            26.4
                                            6.0
                                                       0.97
                                                               True
                                                                      False ...
     1
                      71.0 26.4
                                            6.0
                                                       0.60
                                                               True
                                                                      False ...
     2
                      80.0 26.4
                                            6.0
                                                       1.37
                                                               True
                                                                      False ...
     3
                      62.0 30.5
                                            3.5
                                                       1.00
                                                               True
                                                                      False ...
     4
                      78.0 26.4
                                            6.0
                                                       4.00
                                                               True
                                                                      False ...
        IMT (kg/m2) 2 IMT (kg/m2) 3 Jenis Kelamin Pria Jenis Kelamin Wanita
     0
                False
                               False
                                                     True
                                                                           False
                False
     1
                               False
                                                     True
                                                                           False
     2
                False
                                                                           False
                               False
                                                     True
     3
                False
                               False
                                                    False
                                                                            True
                False
                               False
                                                     True
                                                                           False
        Glukosa Puasa (mg/dL)_0 Glukosa Puasa (mg/dL)_1 \
     0
                           True
                                                    False
     1
                           True
     2
                           True
                                                    False
     3
                                                    False
                           True
     4
                           True
                                                    False
        Cholesterol Total (mg/dL)_normal Cholesterol Total (mg/dL)_tinggi \
```

```
0
                                  True
                                                                      False
1
                                  True
                                                                      False
2
                                  True
                                                                      False
3
                                  True
                                                                      False
4
                                  True
                                                                      False
   Trigliserida (mg/dL)_normal Trigliserida (mg/dL)_tinggi
0
                            True
                                                           False
1
                            True
                                                           False
2
                                                           False
                            True
3
                            True
                                                           False
4
                                                           False
                            True
```

[5 rows x 22 columns]

## 1.6 Model Building

#### Mengubah tipe data object menjadi tipe data integer

data dummy yang telah dibuat memiliki tipe data object, agar bisa dilakukan pembuatan model regresi logistik data harus memiliki tipe data numerik sehingga dilakukan perubahan tipe data object menjadi tipe data integer

```
[]: df = pd.DataFrame(df)
[]: df[['Tekanan darah (S)', 'Tekanan darah (D)', 'Tinggi badan (cm)',
      'Berat badan (kg)', 'Lingkar perut (cm)', 'Fat', 'Visceral Fat', 'Masa Kerja',
      'Usia_0','Usia_1','IMT (kg/m2)_0','IMT (kg/m2)_1','IMT (kg/m2)_2',
      'IMT (kg/m2)_3', 'Jenis Kelamin_Pria', 'Jenis Kelamin_Wanita',
      'Glukosa Puasa (mg/dL)_0', 'Glukosa Puasa (mg/dL)_1',
      'Cholesterol Total (mg/dL)_normal', 'Cholesterol Total (mg/dL)_tinggi',
      'Trigliserida (mg/dL)_normal', 'Trigliserida (mg/dL)_tinggi']] = df[['Tekanan<sub>∪</sub>
      →darah (S)', 'Tekanan darah (D)', 'Tinggi badan (cm)',
      'Berat badan (kg)','Lingkar perut (cm)','Fat','Visceral Fat','Masa Kerja',
      'Usia_0','Usia_1','IMT (kg/m2)_0','IMT (kg/m2)_1','IMT (kg/m2)_2',
      'IMT (kg/m2)_3', 'Jenis Kelamin_Pria', 'Jenis Kelamin_Wanita',
      'Glukosa Puasa (mg/dL)_0', 'Glukosa Puasa (mg/dL)_1',
      'Cholesterol Total (mg/dL)_normal', 'Cholesterol Total (mg/dL)_tinggi',
      'Trigliserida (mg/dL)_normal', 'Trigliserida (mg/dL)_tinggi']].astype(int)
[]: df.info()
```

```
Tekanan darah (D)
                                       1339 non-null
                                                       int64
 1
    Tinggi badan (cm)
                                       1339 non-null
                                                       int64
 2
 3
    Berat badan (kg)
                                       1339 non-null
                                                       int64
 4
    Lingkar perut (cm)
                                       1339 non-null
                                                       int64
 5
    Fat
                                       1339 non-null
                                                       int64
 6
    Visceral Fat
                                       1339 non-null
                                                       int64
 7
    Masa Kerja
                                       1339 non-null
                                                      int64
                                       1339 non-null
 8
    Usia_0
                                                       int64
    Usia 1
                                       1339 non-null
                                                       int64
 10 IMT (kg/m2)_0
                                       1339 non-null
                                                      int64
 11 IMT (kg/m2)_1
                                       1339 non-null
                                                       int64
 12 IMT (kg/m2)_2
                                       1339 non-null
                                                       int64
    IMT (kg/m2)_3
                                       1339 non-null
                                                       int64
 13
    Jenis Kelamin_Pria
                                       1339 non-null
                                                       int64
 15 Jenis Kelamin_Wanita
                                       1339 non-null
                                                       int64
 16 Glukosa Puasa (mg/dL)_0
                                       1339 non-null
                                                       int64
 17 Glukosa Puasa (mg/dL)_1
                                       1339 non-null
                                                       int64
 18 Cholesterol Total (mg/dL)_normal
                                      1339 non-null
                                                       int64
 19 Cholesterol Total (mg/dL)_tinggi
                                      1339 non-null
                                                       int64
                                       1339 non-null
 20 Trigliserida (mg/dL) normal
                                                       int64
21 Trigliserida (mg/dL)_tinggi
                                       1339 non-null
                                                       int64
dtypes: int64(22)
memory usage: 230.3 KB
```

# Split data

Dilakukan split data training dan data testing dengan rasio 70%:30%


```
[]: X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, u orandom_state = 2, shuffle = True, stratify = y)
```

#### Penangan over-sampling dengan SMOTE

```
[]: # Proses SMOTE
sm = SMOTE(random_state=22)
X_train_new, y_train_new = sm.fit_resample(X_train, y_train.ravel())
```

```
[]: pd.Series(y_train_new).value_counts().plot.bar()
```

[]: <Axes: >



#### Implementasi model regresi logistik

dilakukan implementasi regresi logistik pada seluruh variabel, kemudian dilakukan pengecekkan nilai p-value untuk mengetahui variabel mana yang signifikan terhadap model

#### Tahap 1

```
[]: import statsmodels.api as sm
Logit_model = sm.Logit(y_train_new, X_train_new)
result = Logit_model.fit()
print(result.summary2())
```

Optimization terminated successfully.

Current function value: 0.363344

Iterations 11

Results: Logit

Model: Method: Logit MLE Dependent Variable: Pseudo R-squared: 0.476 Date: 2024-04-16 16:29 AIC: 1191.7951 No. Observations: 1596 BIC: 1277.7991 Df Model: Log-Likelihood: 15 -579.90 Df Residuals: 1580 LL-Null: -1106.3Converged: LLR p-value: 6.6687e-215 1.0000

Scale: No. Iterations: 11.0000 1.0000 [0.025 0.975] Coef. Std.Err. P>|z| Tekanan darah (S) 0.0359 0.0120 2.9944 0.0028 0.0124 0.0595 Tekanan darah (D) -0.01440.0157 -0.9173 0.3590 -0.0451 0.0163 Tinggi badan (cm) 0.0829 0.0153 5.4000 0.0000 0.0528 0.1129 0.8245 0.4096 -0.0202 0.0496 Berat badan (kg) 0.0147 0.0178 Lingkar perut (cm) -0.0198 0.0153 -1.2968 0.1947 -0.0498 0.0101 0.0256 -3.5539 0.0004 -0.1410 -0.0408 Fat -0.0909 Visceral Fat 0.0432 -1.3418 0.1797 -0.1425 0.0267 -0.0579 Masa Kerja -0.02960.0193 -1.5301 0.1260 -0.0675 0.0083 0.2167 -7.2483 0.0000 -1.9958 -1.1462  ${\tt Usia\_0}$ -1.5710IMT  $(kg/m2)_0$ -10.59172.4616 -4.3027 0.0000 -15.4164 -5.7670 IMT  $(kg/m2)_1$ -7.6537 2.3511 -3.2554 0.0011 -12.2619 -3.0456 2.3504 -3.5618 0.0004 -12.9780 -3.7648  $IMT (kg/m2)_2$ -8.3714 IMT  $(kg/m2)_3$ -8.3724 2.3082 -3.6272 0.0003 -12.8964 -3.8483 Jenis Kelamin\_Pria 0.2339 -10.8629 0.0000 -2.9993 -2.0824 -2.5409 Glukosa Puasa (mg/dL)\_0 0.0465 0.5317 0.0874 0.9304 -0.9957 1.0886 Trigliserida (mg/dL)\_normal -3.4499 0.2221 -15.5311 0.0000 -3.8853 -3.0146

Dapat diketahui bahwa variabel yang tidak signifikan memiliki nilai p-value di atas 0.05 yaitu variabel Tekanan darah (D), Berat badan (kg), Lingkar perut (cm), Visceral Fat, Masa Kerja, dan Glukosa Puasa (mg/dL). Selantunya dapat dilakukan eliminasi pada variabel yang tidak signifikan untuk dibuat model lagi.

#### Tahap 2

Results: Logit

=

Model: Logit Method: MLE

Dependent Variable: Date: No. Observations: Df Model: Df Residuals: Converged: 2.8998e-36	2024-04-16 1339 9		ng/dL)_tii	AIC: BIC: Log- LL-N		ood:	0.170 951.3528 1003.3495 -465.68 -561.04
No. Iterations:	7.0000			Scal	e:		1.0000
0.975]			Std.Err.	z	P> z	[0.02	5
-							
Tekanan darah (S) 0.0387		0.0219	0.0086	2.5570	0.0106	0.00	51
Tinggi badan (cm) 0.0637		0.0351	0.0146	2.4090	0.0160	0.00	65
Fat		-0.0191	0.0290	-0.6607	0.5088	-0.07	59
0.0376 Usia_0 -0.3742		-0.8026	0.2186	-3.6722	0.0002	-1.23	09
IMT (kg/m2)_0 -1.3499		-6.4826	2.6188	-2.4754	0.0133	-11.61	54
IMT (kg/m2)_1 -0.6095		-5.7741	2.6351	-2.1913	0.0284	-10.93	87
IMT (kg/m2)_2 -0.5596		-5.7737	2.6603	-2.1703	0.0300	-10.98	78
IMT (kg/m2)_3 -0.7350		-5.9589	2.6653	-2.2357	0.0254	-11.18	27
Jenis Kelamin_Pria		-1.3015	0.2563	-5.0785	0.0000	-1.80	38
-0.7992 Trigliserida (mg/dL -2.0546							
=======================================	========						

Dapat diketahui bahwa variabel pada tahap 2 yang tidak signifikan memiliki nilai p-value di atas 0.05 yaitu variabel fat. Selantunya dapat dilakukan eliminasi pada variabel yang tidak signifikan untuk dibuat model lagi.

## Tahap 3

```
'Trigliserida (mg/dL)_tinggi','Usia_1','Tekanan darah (D)','Berat_
     ⇒badan (kg)','Lingkar perut (cm)','Visceral Fat',
              'Masa Kerja', 'Glukosa Puasa (mg/dL)_0', 'Fat'], axis=1)
[]: import statsmodels.api as sm
    Logit_model = sm.Logit(y1,X1)
    result = Logit_model.fit()
    print(result.summary2())
   Optimization terminated successfully.
           Current function value: 0.347941
           Iterations 7
                              Results: Logit
   ______
   Model:
                    Logit
                                               Method:
                                                              MLE
   Dependent Variable: Cholesterol Total (mg/dL)_tinggi Pseudo R-squared: 0.170
                   2024-04-16 16:29
                                               AIC:
                                                             949.7862
   No. Observations: 1339
                                               BIC:
                                                             996.5833
   Df Model:
                                               Log-Likelihood: -465.89
   Df Residuals:
                 1330
                                               LL-Null:
                                                              -561.04
   Converged:
                   1.0000
                                               LLR p-value:
   7.0638e-37
   No. Iterations: 7.0000
                                                      1.0000
                                               Scale:
   Coef. Std.Err. z P>|z| [0.025]
   0.975]
                              0.0215 0.0086 2.5153 0.0119
   Tekanan darah (S)
                                                          0.0048
   0.0383
   Tinggi badan (cm)
                             0.0359 0.0145 2.4710 0.0135 0.0074
   0.0643
                            Usia 0
   -0.3706
   IMT (kg/m2)_0
                             -6.9934 2.5045 -2.7924 0.0052 -11.9020
   -2.0847
   IMT (kg/m2)_1
                             -6.3890 2.4647 -2.5922 0.0095 -11.2197
   -1.5582
   IMT (kg/m2)_2
                             -6.4093
                                     2.4803 -2.5841 0.0098 -11.2705
   -1.5480
                             -6.5953 2.4852 -2.6538 0.0080 -11.4662
   IMT (kg/m2)_3
   -1.7244
   Jenis Kelamin_Pria
                            -1.2563 0.2468 -5.0908 0.0000 -1.7400
```

-2.4950 0.2248 -11.0992 0.0000 -2.9355

-0.7726

Trigliserida (mg/dL)\_normal

```
-2.0544
```

\_\_\_\_\_\_

=

```
[]: # Menambahkan istilah intercept ke variabel X
X_with_intercept = sm.add_constant(X1)

# Membuat dan melatih model regresi logistik dengan istilah intercept
Logit_model = sm.Logit(y1, X_with_intercept)
result = Logit_model.fit()

# Menampilkan nilai intercept
print("Intercept:", result.params['const'])
```

Optimization terminated successfully.

Current function value: 0.347941

Iterations 7

Intercept: -5.277382395663522

## []: print(result.summary2())

Results: Logit

\_\_\_\_\_\_

\_\_\_\_\_

Model: Logit Method:

MLE

Dependent Variable: Cholesterol Total (mg/dL)\_tinggi Pseudo R-squared:

0.170

Date: 2024-04-16 16:49 AIC:

949.7862

No. Observations: 1339 BIC:

996.5833

Df Model: 8 Log-Likelihood:

-465.89

Df Residuals: 1330 LL-Null:

-561.04

Converged: 1.0000 LLR p-value:

7.0638e-37

No. Iterations: 7.0000 Scale:

1.0000

------

-----

Coef. Std.Err. z P>|z| [0.025

0.975]

\_\_\_\_\_\_

-----

const  $-5.2774\ 10374438.1989\ -0.0000\ 1.0000\ -20333530.5071$ 

20333519.9523					
Tekanan darah (S)	0.0215	0.0086	2.5153	0.0119	0.0048
0.0383					
Tinggi badan (cm)	0.0359	0.0145	2.4710	0.0135	0.0074
0.0643					
Usia_0	-0.7988	0.2185	-3.6561	0.0003	-1.2270
-0.3706					
IMT (kg/m2)_0	-1.7160	10374438.1989	-0.0000	1.0000	-20333526.9457
20333523.5137					
IMT $(kg/m2)_1$	-1.1116	10374438.1989	-0.0000	1.0000	-20333526.3413
20333524.1181					
IMT $(kg/m2)_2$	-1.1319	10374438.1989	-0.0000	1.0000	-20333526.3616
20333524.0978					
IMT $(kg/m2)_3$	-1.3179	10374438.1989	-0.0000	1.0000	-20333526.5476
20333523.9118					
Jenis Kelamin_Pria	-1.2563	0.2468	-5.0908	0.0000	-1.7400
-0.7726					
Trigliserida (mg/dL)_norma	1 -2.4950	0.2248	-11.0992	0.0000	-2.9355
-2.0544					
=======================================	=======				

Dapat dilihat seluruh variabel pada model ini telah signifikan yang dilihat dari nilai p-value yang di bawah 0.05. Sehingga model yang diperoleh ini dapat dilanjutkan untuk tes akurasi.

## 1.7 Evaluate model performance

Increase the number of iterations (max\_iter) or scale the data as shown in:
 https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
 https://scikit-learn.org/stable/modules/linear\_model.html#logisticregression
 n\_iter\_i = \_check\_optimize\_result(

#### []: LogisticRegression()

Accuracy of logistic regression classifier on test set: 0.87

#### Confussion matrix

```
[]: from sklearn.metrics import confusion_matrix
  confusion_matrix = confusion_matrix(y_test, y_pred)
  print(confusion_matrix)
```

[[336 4] [48 14]]

[]: from sklearn.metrics import classification\_report print(classification\_report(y\_test, y\_pred))

	precision	recall	f1-score	support
0	0.88	0.99	0.93	340
1	0.78	0.23	0.35	62
accuracy			0.87	402
macro avg	0.83	0.61	0.64	402
weighted avg	0.86	0.87	0.84	402